

开放词汇目标检测与视觉定位：超参数敏感性分析与 Grounding 评估

Student Name: 纪子越, 施皓天, 孙如琦, 黎子涵

Student ID: 12410416, 12312214, 12412620, 12213030

1. Introduction

开放词汇目标检测 (Open-Vocabulary Object Detection, OVD) 突破了传统检测器依赖固定类别表的局限, 允许模型根据任意文本描述 (如“红色背包”或“戴帽子的人”) 来识别物体。与之密切相关的**视觉定位** (Visual Grounding, 又称指代表达理解) 则更进一步: 给定一句自然语言描述 (如“左边打伞的人”), 模型需在图像中精确定位对应目标并输出边界框。两类任务都依赖视觉与语言的联合理解, 是迈向通用交互式视觉系统的重要基础。

然而, 现有方法各有局限。传统闭集检测器在已知类别上精度较高, 但面对新类别无能为力; OWL-ViT [1] 等零样本检测模型虽支持文本查询, 却在 COCO 等密集检测场景下精度明显偏低; Grounding DINO [2] 擅长短语级定位, 但推理开销相对较大。如何在**单卡算力限制**下, 系统评估 YOLO-World [3] 等高效 OVD 框架对训练配置的敏感程度, 并比较不同零样本定位模型在标准 RefCOCO 系列基准 [4], [5], [6] 上的表现, 正是本项目的出发点。

本项目对应 **Topic 4: Open-Vocabulary Object Detection and Visual Grounding**, 包含两条独立但互补的实验路线:

1. **YOLO-World-L 的复现与超参数研究:** 在 COCO 2017 上系统开展 35 组对照实验 (约 170 GPU 小时), 覆盖学习率、优化器、输入分辨率、训练轮数、模型规模、数据增强和骨干冻结等 8 个以上维度。
2. **RefCOCO 子集零样本定位评估:** 受集群调度故障影响, 在本地 Mac 上完成 Grounding DINO 与 OWL-ViT 的定位评估 (每个数据集 200 条样本, 共 600 条/模型), 验证评估流水线并对比两种模型的差异。

我们重点关注两个核心问题: (i) 在 COCO 118K 规模的微调中, 哪些训练配置对检测性能有实质影响; (ii) 零样本定位模型在不同 RefCOCO 变体上的优劣差异及典型失败模式。与只报告单一基准数值的工作不同, 本项目更注重**实证分析的可解释性**和**评估代码的可复现性**。




图 1: 项目流水线总览

图 1. 项目整体流程: 左侧为 COCO 上的 YOLO-World 微调检测, 右侧为 RefCOCO 子集上的零样本定位评估。

2. Related Works

开放词汇目标检测。YOLO-World [3] 将 CLIP 风格的文本编码器嵌入 YOLOv8 检测骨干, 在保留 YOLO 系列实时推理能力的同时支持文本条件检测。其预训练权重已完成大规模视觉-语言对齐, 因此 COCO 微调阶段主要是调整检测头的类别对应关系, 无需从头学习视觉语义。OWL-ViT [1] 则以 ViT 图像编码器为基础, 通过对比学习在块级别 (patch level) 实现零样本检测, 适合开放查询场景, 但在 COCO 全类密集检测上的 mAP 通常偏低。

视觉定位与 Grounding DINO。Grounding DINO [2] 在 DETR 系列检测器 [7] 的基础上引入跨模态特征融合模块, 并通过大规模短语定位预训练获得强大的开放集定位能力。与 YOLO-World “检测 + 文本提示”的范式不同, Grounding DINO 天然面向“图像 + 句子 $\rightarrow$ 边界框”的指代任务, 与 RefCOCO 评估更为契合。

RefCOCO 系列基准。RefCOCO [4] 包含大量日常口语化的指代表达; RefCOCO+ [5] 禁止使用绝对位置词 (如 left/right), 要求模型仅依赖外观和相对关系进行定位; RefCOCOg [6] 的表达更长、更复杂, 更接近自然对话风格。三者难度依次递增, 共同构成视觉定位研究的标准评测套件。

与本项目的关联。已有工作通常以全量验证集上的最优性能为目标, 鲜少关注单卡约束下的训练过程细节。本项目在此方向上进行精细化消融, 同时搭建轻量化定位评估流水线, 在集群资源受限时也能对零样本模型进行公平比较。

3. Method

本项目不提出新模型, 而是对现有方法进行复现、系统扫描和分析。

3.1 YOLO-World-L 微调

我们基于 Ultralytics 框架 [8] 在 COCO 2017 [9] 上微调 **YOLO-World-L**(预训练权重 yolov8l-worldv2.pt)。COCO 的 80 个类别名称以文本提示的形式传入模型, 检测头输出对应的边界框与置信度分数。默认优化配置为 AdamW、权重衰减 0.05、预热 1000 步。

超参数研究遵循**分阶段控制变量**的原则: 先固定 6 epoch 的短程训练快速扫描学习率 (7 个候选值) 和优化器 (AdamW vs SGD), 再逐一消融批次大小、权重衰减、预热步数、输入分辨率 (320/640/800px)、训练轮数 (24/48 epoch)、模型规模 (S/M/L)、四种数据增强设置以及骨干冻结策略。每次实验仅改变被测维度, 其余超参均固定为基线配置 (lr=5e-5, bs=8, 640px), 以保证结果的可比性。

3.2 零样本定位基线

- **Grounding DINO (base)** [2], [10]: 调用 Hugging Face 的 GroundingDinoForObjectDetection, 对每条指代表达取置信度最高的预测框 (top-1), 置信度阈值设为 0.25。
- **OWL-ViT (base-patch32)** [1], [11]: 以短语定位模式运行, 文本输入截断至 16 个 token (模型硬性限制), 阈值 0.1, 批次大小为 1。

两个模型均不在 RefCOCO 上进行微调, 直接以零样本方式推理, 从而隔离预训练能力的差异。

3.3 统一评估流水线

评估代码包含以下模块: refcoco_dataset.py (兼容官方 REFER 格式与 PaDT jsonl 备用格式)、metrics.py (计算 IoU、Acc@0.5、Acc@0.75 并导出 JSON 汇总结果), 以及分别面向 GDINO 和 OWL-ViT 的 eval_refcoco.py。子集采样统一取 PaDT val jsonl 的前 200 行, 确保两个模型在完全相同的样本上进行比较。

4. Experiments

4.1 数据集

数据集	用途	使用规模
COCO 2017 RefCOCO / + / g	OVD 微调与验证 视觉定位 (验证子集)	训练集 118K 张 / 验证集 5K 张, 80 类 每个数据集 200 条指代表达

定位评估使用 PaDT 提供的 RefCOCO val jsonl, 图像来自 COCO 2017 (600 条表达共涉及 79 张不重复图片)。三个 RefCOCO 变体的难度依次递增——RefCOCO+ 禁止位置词、RefCOCOg 表达更长——有助于分析模型对不同表达类型的适应能力。

4.2 实现细节

检测实验 (服务器 NVIDIA L40 48GB)

- 框架: Ultralytics 8.4.60, PyTorch 2.5.1+cu121
- 基线配置: 学习率 $2e-4$, AdamW, 批次大小 8, 分辨率 640px, 训练 12 epoch
- 最优配置: 学习率 $5e-5$, AdamW, 批次大小 8, 分辨率 800px, 训练 24 epoch, 权重衰减 0.05
- 共完成 35 组实验, 累计约 170 GPU 小时; 最优 12-epoch 配置重复运行两次, 均达到 $mAP50=0.677$, 验证了结果的稳定性

定位实验 (本地 Mac M3, MPS 加速)

- 运行环境: Python 3.14, PyTorch 2.12, transformers 4.47 及以上版本
- 每个数据集评估 200 条样本; GDINO 约用时 39 分钟, OWL-ViT 约 3 分钟

4.3 评估指标

- 目标检测: COCO 标准指标 $mAP50$ (IoU 阈值 0.50) 和 $mAP50-95$ (IoU 0.50 至 0.95 的平均值)
- 视觉定位: $Acc@0.5$ / $Acc@0.75$ (预测框与真实框的 IoU 是否达到阈值), 以及 mean IoU (top-1 预测框与真实框的平均交并比)

4.4 实验设计与结果

4.4.1 YOLO-World 超参数研究 为在约 160 GPU 小时的预算内覆盖 8 个维度, 我们对大多数超参采用“单因素、短程 (6 epoch) 扫描”策略; 分辨率、训练轮数和模型规模的关键结论在 12–24 epoch 的完整训练中进一步确认。图 2 中各超参的影响量级, 定义为该维度最优与最差配置之间的 $mAP50$ 差值。

图 2. 各超参数对 $mAP50$ 的近似影响量级 (基于 35 组对照实验)。

图 3. 主要扫描结果: (a) 学习率, (b) 优化器, (c) 分辨率 vs 训练轮数, (d) 模型规模。

学习率。图 3(a) 显示, $mAP50$ 在 $5e-5$ 至 $2e-4$ 的范围内形成一个较宽的性能平台 (6 epoch 时约为 0.661–0.671), 说明 YOLO-World 的预训练权重已提供了良好的初始化, 微调过程对学习率的选取并不特别敏感。当学习率超过 $3e-4$ 后, 性能开始持续下滑 ($1e-3$ 时 $mAP50$ 跌至 0.611), 这可能是过大的更新步长破坏了 BatchNorm 统计信息和检测头的收敛。最终的 24-epoch 全量训练选用 $5e-5$, 相比默认的 $2e-4$ 基线在 12 epoch 时表现更佳 ($mAP50$ 0.677 vs 0.661)。

优化器。如图 3(b) 所示, SGD 在所有测试学习率下均灾难性地失败 ($mAP50$ 分别为 0.248 / 0.081 / 0.021)。YOLO-World 融合了 BatchNorm 和多尺度特征, 不同层之间的梯度尺度差异较大, 这恰恰需要 AdamW 的自适应步长来稳定优化; 而 SGD 的固定步长在此场景下显然力不从心。这一现象与现代 CNN 检测器普遍选用自适应优化器的经验完全吻合。




图 2: 超参数重要性排序




图 3: 超参数扫描四宫格

分辨率与训练轮数。图 3(c) 的结果清楚地表明, 提高输入分辨率比单纯延长训练更有效: 800px 训练 12 epoch (mAP50 0.686) 的效果已接近 640px 训练 24 epoch (0.685); 即便将 640px 的训练延长至 48 epoch (mAP50 0.690), 仍不及 800px 训练 24 epoch (**0.694**)。这是因为更高分辨率有助于检测小目标和精确定位目标边界; 而使用 320px 时, mAP50 仅有 0.584, 较 640px 低了 0.093。实践建议: **在算力允许的前提下, 优先提高输入分辨率, 再考虑增加训练轮数。**

模型规模。图 3(d) 表明 $L > M > S$ 的排序在各训练设置下始终稳定: 24 epoch 时三者 mAP50 分别为 0.694 / 0.659 / 0.605, L 比 S 高出约 0.09。从 12 epoch 延长至 24 epoch 对三种规模的提升幅度相近 (约 $+0.01-0.017$), 说明 S 与 L 之间的差距主要来自模型表达能力的上限, 而非训练不充分。

影响较小的因素。批次大小 (4/8/16)、权重衰减 ($1e-5$ 至 $1e-2$) 和预热步数 (0/500/2000) 对最终 mAP50 的影响均不超过 0.005, 说明在 COCO 118K 的数据规模下, 数据本身已提供了充分的隐式正则化。数据增强的消融实验 (分别关闭 mosaic、自动增强、随机擦除、缩小缩放比例) 合计影响也不足 0.005, 其中关闭 mosaic 的损失最大, 也仅为 0.004。冻结骨干网络最多损失 0.003 mAP50 (800px 下为 0.685 vs 0.686), 在需要节省计算资源时是一个几乎无损的加速手段。

因素	主要发现	影响量级 (mAP50)
优化器	SGD 完全失败, 必须使用 AdamW	0.677→0.021
模型规模	$L > M > S$, 差距稳定	$\sim +0.10$
输入分辨率	800px 最优, 320px 严重下降	$+0.102$
学习率	$5e-5-2e-4$ 为性能平台区	最多 $+0.06$
训练轮数	24 epoch 有一定提升, 但效果不及分辨率	$+0.017$
数据增强 / 权重衰减 / 预热 / 批次大小	影响极小	$< \pm 0.005$
冻结骨干	几乎无损失, 可用于加速	-0.003

最优结果: $\text{mAP50} = 0.694, \text{mAP50-95} = 0.528$ (YOLO-World-L, 800px, 24 epoch, $\text{lr}=5e-5$, AdamW)。

零样本检测对照。OWL-ViT 在 COCO val 上的 mAP50 仅为 0.064 (mAP50-95 0.040), 约为微调后 YOLO-World-L 的 1/11。这一对比说明, 在 COCO 这类固定类别、实例密集的检测场景下, 领域内微调仍然不可或缺; 零样本 ViT 检测器更适合用于开放查询或类别泛化场景, 而非直接替代经过优化的检测流水线。

4.4.2 RefCOCO 子集定位评估(每数据集 $n=200$) 由于集群调度系统持续报错 (Invalid qos specification), 本部分评估改在本地 M3 上完成。




图 4: 检测与定位结果对比

图 4. (a) COCO 检测: 微调 YOLO-World-L 与零样本 OWL-ViT 的性能对比; (b) RefCOCO 子集 $\text{Acc}@0.5$ 结果。

定量结果 (Acc@0.5 / Acc@0.75 / mean IoU)

数据集	GDINO Acc@0.5	OWL Acc@0.5	GDINO Acc@0.75	OWL Acc@0.75	GDINO IoU	OWL IoU
refcoco	0.085	0.210	0.035	0.195	0.093	0.224
refcoco+	0.100	0.300	0.075	0.260	0.108	0.287
refcocog	0.260	0.305	0.230	0.270	0.275	0.322
总体	0.148	0.272	0.113	0.242	0.159	0.278




图 5: 定位定性样例

图 5. 定性对比示例 (绿框 = 真实框, 橙框 = *GDINO* 预测, 紫框 = *OWL-ViT* 预测)。

结果分析。

1. **OWL-ViT** 在整体上优于 **Grounding DINO** (Acc@0.5: 0.272 vs 0.148; mean IoU: 0.278 vs 0.159)。差距在 refcoco 和 refcoco+ 上最为显著 (Acc@0.5 相对高出约 2.5–3 倍), 在 refcocog 上则明显缩小 (0.305 vs 0.260)。一个可能的解释是: OWL-ViT 基于块级对比预训练, 对较短的指代短语有更强的匹配能力; 而 RefCOCO+ 禁用位置词后, Grounding DINO 所依赖的空间关系信息受到限制, OWL-ViT 的外观匹配优势因此更为突出。
2. 两种模型在 RefCOCOg 上的表现均明显优于 refcoco 和 refcoco+ (GDINO 0.260, OWL-ViT 0.305, 而 refcoco/+ 上仅为 0.085–0.100)。这可能是因为 RefCOCOg 的描述更加详细、目标也更为显著, 有助于零样本模型的定位; 而较短、歧义更多的 refcoco/+ 表达则更容易造成 top-1 选框错误。
3. **Acc@0.75** 整体偏低 (GDINO 0.113, OWL-ViT 0.242), 说明即使模型大致命中了目标区域, 其边界框的精确程度也往往不足。这与零样本模型缺乏针对 RefCOCO 边界框回归的专项训练有直接关系。

4. 绝对数值远低于文献中全量验证集的结果（经微调的模型通常可超过 $\text{Acc}@0.5$ 0.70）。造成这一差距的原因主要有三：(i) 本实验为零样本评估，模型未在 RefCOCO 上进行微调；(ii) 使用的是固定的 200 条子集，而非官方完整验证集；(iii) OWL-ViT 对文本的 16-token 截断可能损失了部分长句中的关键信息。值得注意的是， $n=20$ 和 $n=100$ 的小规模预实验与 $n=200$ 呈现出一致的趋势，表明本次子集评估的比较结论是可靠的。

4.4.3 局限性

- 定位评估仅使用了 PaDT val jsonl 的前 200 行，而非全量约 26K 条验证数据。本实验结论适用于方法横向比较和流水线验证，不宜直接与文献中的 SOTA 绝对值进行比较。
- YOLO-World 的所有实验均在单张 L40 GPU 上完成，未探索多卡训练时批次大小与学习率的线性缩放规律。
- 两种定位模型均未在 RefCOCO 上进行微调，也未尝试模型集成，与 YOLO-World 统一定位头方案的比较留待后续工作。

5. Conclusion

本项目围绕开放词汇目标检测微调和零样本视觉定位两条主线展开。在 COCO 2017 上，35 组 YOLO-World-L 对照实验表明：优化器选择 (AdamW vs SGD) 和输入分辨率是影响检测性能的最关键因素；学习率在较宽范围内保持平台，而数据增强、权重衰减、预热步数和批次大小在 COCO 118K 规模下几乎可以忽略不计。最优配置（分辨率 800px，训练 24 epoch，学习率 $5e-5$ ）达到 **mAP50 0.694**，较零样本 OWL-ViT 的检测性能 (0.064) 提升约一个数量级。

在 RefCOCO 600 条子集的定位实验中，**OWL-ViT 整体优于 Grounding DINO** ($\text{Acc}@0.5$: 0.272 vs 0.148)，在较短指代表达的数据集上优势尤为明显；两者在 RefCOCOG 长句上的差距则有所收窄。本项目还交付了一套可复现的定位评估代码，在集群资源不可用的情况下也能在本地完成验证。

后续方向包括：集群恢复后运行全量验证集评估；对定位模型在 RefCOCO 上进行任务专项微调；以及探索将 YOLO-World 的文本提示机制直接用于指代定位任务，实现检测与定位的统一接口。

Contributions

纪子越 (12410416): 项目整体协调；YOLO-World 基线搭建及学习率/优化器扫描实验；超参数重要性分析。

施皓天 (12312214): 分辨率、训练轮数及模型规模对照实验；数据增强消融与骨干冻结研究；COCO 检测结果汇总整理。

孙如琦 (12412620): RefCOCO 定位评估流水线实现；本地 $n=200$ 子集评估；实验日志记录与报告撰写。

黎子涵 (12213030): 服务器环境配置与训练任务管理；OWL-ViT 零样本 COCO 基线评估；文档整理与实验可复现性验证。

Reference

- [1] M. Minderer 等, 《Simple Open-Vocabulary Object Detection with Vision Transformers》, 收入 *Proceedings of the European Conference on Computer Vision (ECCV)*, Springer, 2022, 页 728~755.
- [2] S. Liu 等, 《Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection》, *arXiv preprint arXiv:2303.05499*, 2023, 载于: <https://arxiv.org/abs/2303.05499>
- [3] T. Cheng, L. Song, Y. Ge, W. Liu, X. Wang, 和 Y. Shan, 《YOLO-World: Real-Time Open-Vocabulary Object Detection》, *arXiv preprint arXiv:2401.17270*, 2024, 载于: <https://arxiv.org/abs/2401.17270>

- [4] L. Yu, P. Poirson, S. Yang, A. C. Berg, 和 T. L. Berg, 《Modeling Context in Referring Expressions》, 收入 *Proceedings of the European Conference on Computer Vision (ECCV)*, Springer, 2016, 页 69~85.
- [5] J. Mao, J. Huang, A. Toshev, O. Camburu, A. L. Yuille, 和 K. Murphy, 《Generation and Comprehension of Unambiguous Object Descriptions》, 收入 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, 页 11~20.
- [6] V. K. Nagaraja, V. I. Mori, 和 A. G. Schwing, 《Modeling Context between Objects for Referring Expression Understanding》, 收入 *Proceedings of the Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, 2016, 页 844~856.
- [7] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, 和 S. Zagoruyko, 《End-to-End Object Detection with Transformers》, *Proceedings of the European Conference on Computer Vision (ECCV)*, 页 213~229, 2020.
- [8] Ultralytics, 《YOLO-World Documentation》. <https://docs.ultralytics.com/models/yolo-world/>, 2024 年.
- [9] T.-Y. Lin 等, 《Microsoft COCO: Common Objects in Context》, 收入 *Proceedings of the European Conference on Computer Vision (ECCV)*, Springer, 2014, 页 740~755.
- [10] Hugging Face, 《IDEA-Research/grounding-dino-base Model Card》. <https://huggingface.co/IDEA-Research/grounding-dino-base>, 2024 年.
- [11] Hugging Face, 《google/owlvit-base-patch32 Model Card》. <https://huggingface.co/google/owlvit-base-patch32>, 2024 年.